RAG cho hỏi đáp quy định đào tạo HCMUS

Seminar S07 · CS420 Nhập môn Trí tuệ nhân tạo

Trịnh Võ Nam Kiệt · Tuấn Lĩnh · Trần Đăng Lê Huy

Trường Đại học Khoa học Tự nhiên, ĐHQG-HCM

Tóm tắt

Nghiên cứu khảo sát câu hỏi liệu cung cấp tài liệu ngoài có loại bỏ hallucination khi mô hình ngôn ngữ trả lời về quy định đào tạo hay không. Nhóm xây dựng kho 162 chunk từ bốn văn bản công khai của Trường Đại học Khoa học Tự nhiên, ĐHQG-HCM và đánh giá trên 20 câu có 30 nhóm bằng chứng. Thí nghiệm truy hồi so sánh TF-IDF, BM25 và embedding BGE-M3 tại k = 1, 3, 5. BM25 đạt Evidence Recall@1 cao nhất với 80,00%, còn BGE-M3 đạt Evidence Recall@5 cao nhất với 89,17%. Một lượt sinh 80 đáp án dùng chung Qwen2.5-1.5B-Instruct cho bốn nhánh. Theo chấm GPT sơ bộ, TF-IDF và BGE-M3 đúng nội dung chính ở 10/20 câu, BM25 ở 9/20 câu và baseline không RAG ở 0/20 câu. Cả 60 đáp án RAG đều thiếu ID trích dẫn hợp lệ theo định dạng yêu cầu. Các ca lỗi cho thấy model có thể chọn nhầm điều kiện hoặc đọc sai cột ngay khi nhận được bằng chứng đúng. Hệ thống cần kết hợp truy hồi, kiểm tra điều kiện và xác minh từng kết luận với nguồn.

Từ khóa · RAG, truy hồi thông tin, hallucination, quy chế đào tạo, trích dẫn.

1 Giới thiệu

Khi hỏi về số tín chỉ, điều kiện tốt nghiệp hay học phí, người đọc cần biết quy định thuộc văn bản nào, áp dụng cho khóa nào và có ngoại lệ gì. Mô hình ngôn ngữ có thể sinh câu trả lời trôi chảy từ trọng số đã học nhưng vẫn nêu sai số liệu hoặc gán quy định cho nhầm đối tượng. Câu hỏi dẫn dắt của seminar S07 là liệu cung cấp tài liệu ngoài có loại bỏ hallucination trong mô hình ngôn ngữ hay không [13].

Nhóm nghiên cứu ba vấn đề. Thứ nhất, bằng chứng đúng xuất hiện ở đâu trong top-k khi thay retriever. Thứ hai, chất lượng nội dung thay đổi thế nào khi giữ cùng generator và đưa vào prompt các đoạn đã truy hồi. Thứ ba, hệ thống mắc lỗi ở đâu khi thiếu nguồn, nhận nguồn lệch trọng tâm hoặc đã nhận đúng nguồn nhưng vẫn diễn giải sai. Phạm vi là bộ câu hỏi trên các phiên bản văn bản được lưu trong corpus. Đơn vị phân tích là từng câu hỏi, đoạn bằng chứng và đáp án sinh ra.

2 Cơ sở lý thuyết và tổng quan nghiên cứu

2.1 Bộ nhớ tham số và bộ nhớ ngoài

Bộ nhớ tham số là thông tin mô hình mã hóa trong trọng số qua quá trình huấn luyện. Đáp án không RAG dựa vào trọng số và prompt câu hỏi. Bộ nhớ ngoài là tập tài liệu có thể truy cập ở thời điểm suy luận. Trong RAG, truy vấn được dùng để chọn một số đoạn và cung cấp chúng cho generator. Kết quả truy hồi có thể được lưu kèm để kiểm tra lại đoạn nào đã đi vào prompt.

Fine-tuning thay đổi trọng số thông qua huấn luyện trên ví dụ bổ sung. Cách này có thể điều chỉnh hành vi hoặc phong cách trả lời, nhưng việc cập nhật quy chế bằng huấn luyện đòi hỏi một lượt thay đổi mô hình. Ghép toàn bộ tài liệu vào prompt cũng cung cấp nguồn ngoài, với chi phí xử lý phụ thuộc vào số token của kho tài liệu. RAG thêm bước chọn đoạn trước khi sinh. Bước chọn giảm lượng văn bản cần đưa vào prompt và tạo thêm điểm có thể sai nếu đoạn cần thiết nằm ngoài top-k.

2.2 Kiến trúc trong nghiên cứu của Lewis và cộng sự

Lewis và cộng sự [1] nghiên cứu cách phối hợp bộ nhớ tham số của mô hình sinh với một chỉ mục đoạn Wikipedia. Bộ truy hồi dày DPR mã hóa truy vấn và đoạn để tìm ứng viên theo tích vô hướng. Generator BART sinh đầu ra có điều kiện theo truy vấn và đoạn. Tài liệu được xem là biến ẩn. RAG-Sequence lấy tổng có trọng số ở cấp chuỗi, còn RAG-Token lấy tổng ở từng bước token.

Trên Natural Questions, Bảng 1 của bài báo ghi điểm Exact Match 44,5 cho RAG-Sequence, 44,1 cho RAG-Token và 36,6 cho baseline T5-11B+SSM chỉ dùng bộ nhớ tham số. Trên WebQuestions, RAG-Token đạt 45,5 và RAG-Sequence đạt 45,2, cho thấy thứ tự có thể đổi theo bộ câu hỏi. Các tác giả cũng quan sát ít lỗi thực tế hơn BART trong phân tích định tính ở bài toán sinh đáp án MS MARCO [1]. Thí nghiệm HCMUS dùng Qwen và ghép các đoạn top-k vào cùng một prompt để khảo sát văn bản quy chế [6, 11–12].

2.3 Khả năng xác minh của câu trả lời

Schneider [2] khảo sát các yêu cầu về giải thích cho hệ thống AI sinh, trong đó khả năng xác minh giúp người đọc đối chiếu nội dung với căn cứ. Nhóm áp dụng ý tưởng đó bằng cách phân biệt ba phép kiểm tra. Đoạn đúng cần được truy hồi. Kết luận phải được đoạn đã cung cấp hỗ trợ. Mã trích dẫn phải dẫn được đến đoạn cụ thể và vị trí trong văn bản. Ba phép kiểm tra có thể cho kết quả khác nhau trên cùng câu hỏi.

Ví dụ, câu trả lời có thể chứa đúng một mức học phí nhưng nhầm tên cột. Nếu chỉ dò số, phép chấm sẽ bỏ qua sai lệch về ý nghĩa. Một citation có ID đúng cũng cần được kiểm tra theo cùng đối tượng, thời gian và điều kiện của kết luận. Các đặc điểm này định hướng cách nhóm lưu câu trả lời, prompt và ID nguồn trong thí nghiệm.

3 Mô hình xác suất và ví dụ số

3.1 Hai cách biên hóa tài liệu

Gọi x là chuỗi token của câu hỏi và y = (y_1, …, y_t) là đáp án gồm T token. Kho đoạn là Z, mỗi đoạn z ∈ Z. Tập $Z_k(x)$ chứa tối đa k ứng viên có điểm truy hồi cao nhất. η là tham số retriever và θ là tham số generator. $p_\eta(z \mid x)$ là xác suất của đoạn cho truy vấn, còn $p_\theta(y_i \mid x, z, y_{<i})$ là xác suất token tiếp theo khi đã có tiền tố. Xác suất nằm trong [0, 1] và không có đơn vị. k và T là số đếm, với $1 \le k \le |Z|$ và $T \ge 1$. [1]

RAG-Sequence. Với mỗi đoạn, tính xác suất cả chuỗi bằng tích các xác suất token có điều kiện. Sau đó cộng các xác suất chuỗi theo trọng số retriever. Cùng một z được giữ trong toàn bộ tích của một hạng tử.

$$p_{Seq}(y \mid x) \approx \sum_{z \in Z_k(x)} p_\eta(z \mid x) \prod_{i=1}^{T} p_\theta(y_i \mid x, z, y_{<i})$$

RAG-Token. Ở từng bước i, lấy tổng xác suất token theo các đoạn và trọng số retriever. Nhân các tổng theo thứ tự token để có xác suất chuỗi. Mỗi bước có thể dựa nhiều hơn vào một đoạn khác.

$$p_{Tok}(y \mid x) \approx \prod_{i=1}^{T} \left[\sum_{z \in Z_k(x)} p_\eta(z \mid x)\, p_\theta(y_i \mid x, z, y_{<i}) \right]$$

Các công thức dùng top-k để xấp xỉ biên hóa trên toàn kho đoạn. Điều kiện theo tiền tố thể hiện mô hình tự hồi quy. Tổng khối lượng xác suất của tập top-k có thể nhỏ hơn 1 nếu trọng số được định nghĩa trên toàn kho. Ví dụ dưới giả định hai đoạn giữ toàn bộ khối lượng. Điểm cosine và BM25 trong benchmark dùng để xếp hạng. Chúng được lưu dưới dạng score, còn xác suất ở ví dụ số được giả định riêng.

3.2 Ví dụ số hai đoạn và hai token

Xét một câu hỏi x và một đáp án ứng viên y = (a, b). Bảng 1 đặt $p_\eta(z_1 \mid x) = 0{,}70$ và $p_\eta(z_2 \mid x) = 0{,}30$. Xác suất sinh b trong cột cuối được tính khi a đã có trong tiền tố. Các số là giả định để minh họa hai phép tính từ [1].

Bảng 1. Ví dụ hai đoạn và hai token

Đoạn	Trọng số retriever	$p_\theta(a \mid x, z)$	$p_\theta(b \mid x, z, a)$
z_1	0,70	0,80	0,90
z_2	0,30	0,40	0,20

Với RAG-Sequence, hai xác suất chuỗi có điều kiện lần lượt là 0,80 × 0,90 = 0,72 và 0,40 × 0,20 = 0,08. Tổng có trọng số là 0,70 × 0,72 + 0,30 × 0,08 = **0,5280**.

Với RAG-Token, xác suất hỗn hợp ở bước a là 0,70 × 0,80 + 0,30 × 0,40 = 0,68. Ở bước b là 0,70 × 0,90 + 0,30 × 0,20 = 0,69. Xác suất chuỗi là 0,68 × 0,69 = **0,4692**. Khác biệt đến từ vị trí phép tổng so với phép tích. Hai giá trị mô tả cùng một chuỗi ứng viên dưới hai giả định mô hình.

4 Phương pháp thực nghiệm

4.1 Kho tài liệu và câu hỏi

Bốn tài liệu thuộc snapshot của nhóm bao phủ đào tạo, rèn luyện, học phí và ngoại ngữ. Bảng 2 liệt kê nguồn và số trang PDF. Nhóm lưu số văn bản, trang nguồn, phiên bản, phạm vi áp dụng và checksum để truy lại bằng chứng. D02 chứa bản năm 2020 và phần sửa đổi 2023. Phạm vi áp dụng được giữ cùng đoạn để có thể phân biệt quy định cho các nhóm sinh viên khác nhau [7–10].

Bảng 2. Bốn văn bản trong kho thực nghiệm

Mã	Văn bản trong corpus	Trang
D01	Quy chế đào tạo đại học năm 2026, QĐ 3087 [7]	21
D02	Quy chế rèn luyện năm 2020 và sửa đổi năm 2023 [8]	16
D03	Định mức học phí 2026–2027, QĐ 3317 [9]	5
D04	Quy định học ngoại ngữ và chuẩn đầu ra, QĐ 2464 [10]	9
Tổng	Snapshot bốn tài liệu	51

Nhóm chia văn bản theo 80 điều và mục cha thành 162 chunk, với trần 800 token theo cl100k_base kể cả phần ngữ cảnh lặp. Với bảng học phí, chú giải cột có thể được lặp để hàng dữ liệu giữ được ý nghĩa khi đứng riêng. Tập đánh giá gồm 20 câu và 30 nhóm bằng chứng. Mỗi nhóm chứa đoạn tham chiếu và có thể ánh xạ đến nhiều chunk mang cùng bằng chứng. Câu hỏi và đáp án chuẩn được giữ riêng khỏi chỉ mục. [11–12]

4.2 Pipeline và các điểm phát sinh lỗi

Hình 1. Pipeline của nhóm S07 [1, 11–12]



Ở khâu tiếp nhận, OCR có thể làm sai chữ hoặc cột. Khi chia đoạn, một điều kiện có thể nằm tách khỏi quy tắc chính. Chỉ mục phải theo đúng phiên bản tài liệu. Retrieval có thể bỏ sót đoạn cần thiết hoặc đưa đoạn trùng từ lên cao. Bước tạo prompt có thể làm mất điều kiện khi rút ngắn context. Generator có thể diễn giải sai ngay cả khi nhận được đoạn đúng. Log giữ các ID đã truy hồi, đoạn đưa vào prompt và câu trả lời để định vị các lỗi này.

4.3 Ba cấu hình truy hồi

TF-IDF chấm theo cosine trên vector từ và cụm từ với unigram và bigram [3]. BM25 dùng cùng phân đoạn từ cơ bản và biến thể IDF không âm, với $k_1 = 1{,}5$ và $b = 0{,}75$ để điều chỉnh bão hòa tần suất và độ dài đoạn [4, 11]. BGE-M3 biểu diễn câu hỏi và chunk thành vector dày, chuẩn hóa L2 rồi xếp theo cosine. Nhóm dùng nhánh dense của BGE-M3 [5, 11]. Cả ba được đánh giá trên cùng câu hỏi và quy ước ánh xạ bằng chứng.

5 Thiết kế đánh giá và ví dụ truy vết

5.1 Phép đo và điều kiện sinh

Với một câu q có m nhóm bằng chứng và tìm được r nhóm trong top-k, Evidence Recall@k(q) = r/m. Hit@k(q) = 1 nếu r ≥ 1, còn All Evidence Hit@k(q) = 1 nếu r = m. Lấy trung bình theo 20 câu để mỗi câu có trọng số ngang nhau. MRR@k dùng nghịch đảo hạng của hit đầu tiên, gán 0 nếu top-k hụt. Nhãn gộp phần thân và chú giải lặp khi đoạn trích đối chiếu được vị trí trên trang nguồn. [11]

Thí nghiệm sinh câu trả lời gồm 20 câu hỏi × 4 cấu hình. Cùng revision Qwen2.5-1.5B-Instruct, system prompt, greedy decoding, FP32 + SDPA và trần 768 token sinh được giữ cho mọi nhánh. Baseline chỉ nhận câu hỏi, còn TF-IDF, BM25 và embedding nhận thêm top-5. Log lưu prompt, ID context, token, thời gian và audit citation. Với Qwen, các chunk được ghép vào một prompt rồi sinh một đáp án. Phép biên hóa trong Mục 3 được trình bày để giải thích mô hình của Lewis và cộng sự [1, 6, 12].

5.2 Ví dụ truy vết câu Q01

Câu hỏi. Theo Quy chế 2026, học phần tiên quyết khác học phần học trước như thế nào?

Bảng 3. Năm đoạn được BGE-M3 truy hồi cho Q01

Hạng embedding	Chunk ID	Nội dung dùng để đối chiếu
1	D01_regulation_article_3_03	Điều 3 khoản 3(c), trang PDF 4, có cả hai định nghĩa
2	D01_regulation_article_27_01	Điều khoản chuyển tiếp
3	D01_regulation_article_3_02	Mảnh khác thuộc Điều 3
4	D01_regulation_article_6_02	Mảnh thuộc Điều 6
5	D01_regulation_article_18_02	Mảnh thuộc Điều 18

Bảng 3 ghi thứ tự các đoạn trong log của nhánh BGE-M3 [12]. Prompt đặt các đoạn dưới nhãn NGUỒN, kèm ID, tên văn bản, vị trí, phạm vi và URL. Câu hỏi đặt sau context. System prompt yêu cầu dùng nguồn, giữ điều kiện áp dụng và báo thiếu căn cứ khi cần. Đoạn hạng 1 chứa cả yêu cầu học và thi đạt đối với học phần tiên quyết lẫn yêu cầu hoàn thành quá trình học tập đối với học phần học trước. [7, 12]

Đáp án minh họa đã gắn nguồn. Để được đăng ký và theo học học phần A, sinh viên phải học và thi đạt học phần tiên quyết. Với học phần học trước, điều khoản yêu cầu hoàn thành quá trình học tập trước khi đăng ký và theo học A. [D01_regulation_article_3_03] [7]

Đây là diễn giải từ đáp án embedding thật. Model viết “phải học và thi đạt” cho học phần tiên quyết và “phải hoàn thành quá trình học tập” cho học phần học trước. Mã trích dẫn được bổ sung khi đối chiếu Điều 3 khoản 3(c). Baseline nói chung về học trước và bỏ khác biệt thi đạt. [12]

6 Kết quả thực nghiệm

Truy hồi trên cùng corpus. Nhóm dùng 162 chunk từ bốn văn bản của Trường Đại học Khoa học Tự nhiên, ĐHQG-HCM và 20 câu hỏi có 30 nhóm bằng chứng. Chú giải lặp được tính khi xác minh được vị trí nguồn. Evidence Recall là trung bình theo câu của tỷ lệ nhóm bằng chứng tìm thấy. Hit Rate yêu cầu ít nhất một nhóm. Cột đủ bằng chứng yêu cầu tất cả nhóm của câu. MRR là trung bình nghịch đảo thứ hạng bằng chứng đầu tiên, với điểm 0 nếu top-k không có bằng chứng. Nguồn số liệu [11].

Bảng 4. Kết quả truy hồi trên 20 câu hỏi [11]

Retriever	Evidence Recall@1	Recall@3	Recall@5	Hit@5	Đủ nguồn@5	MRR@5
TF-IDF	70,83%	82,50%	82,50%	90%	15/20	0,8250
BM25	80,00%	84,17%	84,17%	90%	16/20	0,8667
BGE-M3	65,00%	81,67%	89,17%	95%	16/20	0,7867

BM25 đưa bằng chứng lên sớm nhất trong lần chạy này, dẫn Evidence Recall ở k = 1 và 3. Từ k = 3 đến 5, Evidence Recall của BM25 giữ ở 84,17%. BGE-M3 tăng mạnh hơn khi mở rộng top-k và phủ nhiều nhóm bằng chứng nhất ở k = 5. Hai phương pháp đạt cùng 16/20 câu đủ nguồn nhưng thiếu ở các câu khác nhau. Chẳng hạn BM25 lấy đủ ba nhóm của Q15, còn BGE-M3 tìm được đoạn tham chiếu về phạm vi khóa tuyển ở Q14. Độ bao phủ cao và thứ hạng đầu cao giúp giải quyết hai nhu cầu khác nhau khi chọn số đoạn cho prompt.

Chất lượng đáp án. Bảng dưới tổng hợp 80 đáp án do bốn cấu hình sinh trên Tesla T4. Tất cả dùng cùng Qwen2.5-1.5B-Instruct, prompt chung, greedy và tối đa 768 token sinh. Các nhánh RAG nhận top-5. Điểm 2 là đúng nội dung chính, 1 là đúng một phần, 0 là sai hoặc chưa có câu trả lời sử dụng được. Đây là chấm GPT sơ bộ, chưa chấm mù và chưa có người duyệt độc lập. Nguồn số liệu [12].

Bảng 5. Kết quả sinh của bốn nhánh theo chấm GPT sơ bộ [12]

Nhánh	Đúng chính	Một phần	Sai hoặc thiếu đáp án	Có khẳng định sai hoặc ngoài nguồn
Không RAG	0/20	3/20	17/20	15/20
TF-IDF	10/20	5/20	5/20	8/20
BM25	9/20	6/20	5/20	7/20
BGE-M3	10/20	6/20	4/20	6/20

TF-IDF và BGE-M3 đồng hạng về số câu đúng chính. BM25 cách một câu. Trên mẫu này, truy hồi cải thiện điểm nội dung và giảm số câu có khẳng định sai hoặc ngoài nguồn. Cả 60 đáp án RAG đều thiếu citation hợp lệ theo mẫu ID chunk đã yêu cầu. Vì vậy, điểm đúng nội dung, độ phủ evidence và tính kiểm chứng của citation được báo cáo riêng.

7 Thảo luận lỗi và cơ chế kiểm tra

Bảng 6. Năm ca lỗi tiêu biểu khi sinh câu trả lời [12]

Câu hỏi	Quan sát từ prompt và đáp án	Vị trí cần xử lý
Q07	Cả ba top-5 hụt đoạn xếp loại 65–79 điểm. Nhánh embedding trả Trung bình 50 điểm cho trường hợp 68 điểm.	Retrieval thiếu ngưỡng cần hỏi. Generator cần nhận ra phần thiếu trước khi kết luận.
Q01	Đoạn định nghĩa đúng đứng đầu ở cả ba nhánh. TF-IDF và BM25 có thêm đoạn về Anh văn ở hạng 2, và đáp án chuyển sang quy định Anh văn.	Có đoạn nhiễu cùng từ khóa. Cần kiểm tra câu trả lời có giải quyết đúng cặp khái niệm được hỏi.
Q05	Embedding đã nhận Điều 19 nhưng khẳng định đủ tín chỉ là đủ tốt nghiệp. BM25 liệt kê thêm điều kiện nhưng bỏ điều kiện về đình chỉ.	Generator chọn sai hoặc bỏ điều kiện có sẵn. Cần đối chiếu danh sách điều kiện trước khi trả lời.
Q13	Cả ba nhận đủ bảng và chú giải. BM25 và embedding lấy sai cột. TF-IDF nêu chênh 40.000 đồng nhưng gán nhãn C1 cho khối chuyên nghiệp.	Trích xuất bảng và gán nguồn cho số liệu. Cần kiểm tra cột C5 và tính hiệu từ hai ô đã xác minh.
Q19	TF-IDF nêu được thời hạn và các mốc nhưng thêm hậu tố quyết định sai. Embedding bỏ mất thời hạn hai năm.	Kiểm tra cả nội dung quy định và thông tin văn bản dùng để dẫn nguồn.

Các ca trên đều thuộc lượt sinh dùng trần 768 token. Log ghi nhận đủ context đã chọn và không có đáp án chạm trần. Lỗi ở Q05 và Q13 xảy ra sau khi bằng chứng phù hợp đã vào prompt. Q07 minh họa một chuỗi lỗi khác. Đoạn chứa ngưỡng không vào top-5, sau đó model lấy quy định gần chủ đề để kết luận cho sai trường hợp. [12]

Kiểm tra trước khi công bố đáp án. Có thể yêu cầu cấu trúc gồm trạng thái đủ nguồn, kết luận, mã chunk và đoạn hỗ trợ. Hệ thống kiểm tra mã thuộc context và đoạn trích có trong văn bản, rồi đối chiếu điều kiện như khóa tuyển, năm học, chương trình hoặc trạng thái chứng chỉ. Với bảng, lưu giá trị cùng nhãn hàng, tên cột và đơn vị. Chỉ tính chênh lệch sau khi xác nhận hai ô cùng cột C5 và cùng phạm vi. Khi thiếu căn cứ, hệ thống có thể truy hồi lại có giới hạn hoặc báo rõ thông tin chưa đủ. Cách kiểm tra nguồn này vận dụng tiêu chí khả năng xác minh trong thảo luận về GenXAI [2].

Cập nhật văn bản. Lưu định danh quyết định, ngày và phạm vi áp dụng, quan hệ sửa đổi, số trang và hash tệp. Khi có bản mới, rà đoạn thay đổi, tạo lại chỉ mục cho phần ảnh hưởng và chạy lại các câu liên quan đến văn bản đó. Giữ phiên bản của chỉ mục và bộ câu hỏi để truy lại căn cứ của từng lần chạy. Kiểm tra theo nhóm đối tượng giúp tránh trộn quy định cũ và mới khi cùng xuất hiện trong kết quả.

8 Giới hạn và điều kiện áp dụng

Kho dữ liệu thực nghiệm có 51 trang, rộng hơn quy mô 5–10 trang gợi ý trong đề S07. Các chỉ số phản ánh cách chia 162 chunk hiện tại, cách ánh xạ quote và 20 câu đã soạn từ chính miền tài liệu. Các câu so sánh nhiều điều khoản phụ thuộc mạnh vào chất lượng nhãn bằng chứng. Chẳng hạn metadata phạm vi có thể hỗ trợ kết luận Q14 dù chunk chứa quote tham chiếu chưa lọt top-5. Ngược lại, một câu có Hit@5 vẫn có thể thiếu phần bằng chứng cần thiết để trả lời đủ. [11–13]

OCR của 29 trang và điểm GPT còn chờ duyệt độc lập. Nhóm chưa có tập câu hỏi giữ lại để đánh giá khả năng khái quát hoặc phép thử tách riêng nhiễu context, prompt và năng lực generator. Chênh lệch một câu giữa các nhánh RAG tương ứng 5 điểm phần trăm trên mẫu 20 câu. Bảng điểm của lượt ba phương pháp với giới hạn sinh 384 token và bảng bốn nhánh với giới hạn 768 token mô tả hai cấu hình khác nhau. Đánh giá trên câu mới và chấm chéo có thể làm thay đổi thứ tự phương pháp. [11–12]

RAG hữu ích khi có tài liệu đúng phiên bản, thông tin có thể truy hồi và người dùng cần kiểm tra nguồn. BM25 đưa nhiều bằng chứng lên hạng đầu khi câu hỏi dùng thuật ngữ hoặc số điều đặc trưng. BGE-M3 cho độ phủ cao hơn ở top-5 trong corpus này. Câu hỏi nhiều điều khoản hoặc phải đọc bảng vẫn cần kiểm tra độ đủ nguồn và điều kiện áp dụng. Tăng số chunk còn làm tăng lượng context cần xử lý. Trong thí nghiệm bốn cấu hình, đầu vào trung bình của ba nhánh RAG khoảng 2.749–3.205 token, so với 236 token ở baseline. [11–12]

9 Kết luận

Trên 20 câu hỏi quy định HCMUS, việc đưa tài liệu vào prompt giúp Qwen trả đúng nội dung chính ở 9–10 câu tùy retriever, so với 0 câu ở baseline theo chấm sơ bộ. Những lỗi như lấy sai ngưỡng điểm, nhầm điều kiện tốt nghiệp và nhầm cột học phí vẫn xuất hiện. Vì vậy, kết quả thực nghiệm trả lời câu hỏi nghiên cứu rằng tài liệu ngoài có thể giảm lỗi nhưng chưa loại bỏ hallucination.

Kết quả của Lewis và cộng sự [1] mô tả kiến trúc biên hóa theo đoạn và các tác vụ tri thức trong nghiên cứu gốc. Kết quả của nhóm [11–12] đánh giá một pipeline ghép context và sinh bằng Qwen trên corpus nhỏ. Hai phần cùng cho thấy giá trị của truy cập bộ nhớ ngoài trong phạm vi thí nghiệm tương ứng. Với bản triển khai của nhóm, ba hướng kiểm tra ưu tiên là độ đủ bằng chứng, tính đúng của các điều kiện được trích và khả năng truy ngược từng kết luận về văn bản nguồn.

Tài liệu tham khảo

[1] Lewis, P. và cộng sự (2020). Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks. NeurIPS 33, 9459–9474. Bài báo.

[2] Schneider, J. (2024). Explainable Generative AI (GenXAI): a survey, conceptualization, and research agenda. Artificial Intelligence Review, 57, 289. DOI 10.1007/s10462-024-10916-x.

[3] Salton, G. và Buckley, C. (1988). Term-weighting approaches in automatic text retrieval. Information Processing & Management, 24(5), 513–523. DOI 10.1016/0306-4573(88)90021-0.

[4] Robertson, S. và Zaragoza, H. (2009). The Probabilistic Relevance Framework BM25 and Beyond. Foundations and Trends in Information Retrieval, 3(4), 333–389. DOI 10.1561/1500000019.

[5] Chen, J. và cộng sự (2024). M3-Embedding Multi-Linguality, Multi-Functionality, Multi-Granularity Text Embeddings Through Self-Knowledge Distillation. arXiv 2402.03216.

[6] Qwen Team (2024). Qwen2.5 Technical Report. arXiv 2412.15115.

[7] Trường ĐH Khoa học Tự nhiên, ĐHQG-HCM (2026). Quy chế đào tạo trình độ đại học, QĐ 3087/QĐ-KHTN. Trang công bố.

[8] Trường ĐH Khoa học Tự nhiên, ĐHQG-HCM. Quy chế đánh giá kết quả rèn luyện năm 2020 và sửa đổi năm 2023. PDF lưu trong corpus.

[9] Trường ĐH Khoa học Tự nhiên, ĐHQG-HCM (2026). Định mức học phí năm học 2026–2027, QĐ 3317/QĐ-KHTN. PDF lưu trong corpus.

[10] Trường ĐH Khoa học Tự nhiên, ĐHQG-HCM (2026). Quy định về việc học ngoại ngữ và chuẩn trình độ ngoại ngữ khi tốt nghiệp, QĐ 2464/QĐ-KHTN. PDF lưu trong corpus.

[11] Nhóm S07 (08/11/2026). Benchmark truy hồi TF-IDF, BM25 và BGE-M3, commit 5771d80. Kết quả, cấu hình và dữ liệu.

[12] Nhóm S07 (08/11/2026). Thí nghiệm so sánh bốn cấu hình sinh câu trả lời, 80 đáp án. Kết quả, cấu hình và điểm GPT sơ bộ, commit 3bb5f3a.

[13] CS420 Nhập môn Trí tuệ nhân tạo. Đề tài seminar S07. Đề bài.

[14] OpenAI (08/11/2026). Codex, công cụ hỗ trợ tổng hợp dữ liệu và soạn thảo báo cáo. Điểm nội dung trong thí nghiệm đến từ lượt chấm GPT được ghi trong metadata [12].